

# Analisis de los Impactos Observados en el Festival Cruïlla

César Aparicio Crespo

9, 10 y 11 de Julio de 2025

## Índice

|                                                           |          |
|-----------------------------------------------------------|----------|
| <b>1. Discusión</b>                                       | <b>2</b> |
| 1.1. Hipersexualización de mujeres . . . . .              | 2        |
| 1.2. "Adultificación" de menores . . . . .                | 2        |
| 1.3. Estereotipación racial y distorsión étnica . . . . . | 4        |
| 1.4. Alteración de la identidad de género . . . . .       | 4        |
| <b>2. Conclusiones</b>                                    | <b>4</b> |

## 1 Discusión

Los avances en inteligencia artificial han provocado que su uso cotidiano, tanto profesional como lúdico, se haya generalizado y democratizado a una población heterogénea y con sensibilidades muy diferentes. Pero aún con esta evolución, la IA sigue lejos de ser perfecta, y en esta mejora constante su falta de rigor, en algunos casos, puede dar pie a conflictos en la nueva interacción humano-IA (HAI por sus siglas en inglés). La llegada de tecnologías como la IA generativa ha traído consigo un gran número de problemas éticos, en primer lugar, por razonar de manera simplista frente a una realidad altamente compleja y, en segundo lugar, por aprender sobre datos recopilados de situaciones pasadas, que llevan a la IA a realizar deducciones estadísticas [16]. Abordar los riesgos y daños que esto puede causar es fundamental no solo porque ya han tenido cierto impacto y es probable que persistan, sino también porque pueden agravarse y acumularse en el tiempo [13].

El Marco de Gestión de Riesgos de la IA (AI RMF), desarrollado por el Instituto Nacional de Estándares y Tecnología de Estados Unidos (NIST), enfatiza la *identificación* y *priorización* de dichos daños como paso crítico para abordar los riesgos asociados a la inteligencia artificial [17]. Pero aunque cada vez sean más los estudios que materializan esta identificación de los riesgos y daños en distintos ámbitos y aplicaciones, mapeándolos en diferentes taxonomías [3, 4, 5, 8, 14, 20, 21, 25, 27], gran parte de este trabajo carece aún de base en evidencias reales y, a menudo, no aborda *quién* se ve afectado o *cómo* surge el riesgo o el daño, lo que limita su eficacia para orientar la priorización y la mitigación de riesgos [13]. Si bien trabajos previos han propuesto marcos para identificar dónde falla la tecnología [6, 12, 15, 18, 22], gran parte de ellos se centran en fallos técnicos, carecen de una base en evidencias reales y no consideran cómo la IA generativa puede inducir un panorama único de fallos y riesgos en comparación con otras tecnologías de inteligencia artificial [13].

En este trabajo, y fruto de la participación de los prototipos en el entorno del Festival Cruïlla, se han podido observar y analizar varios ejemplos de *daños de representación* -aquellos en los que los sistemas refuerzan estereotipos o invisibilizan a ciertos grupos [23], entre otros impactos-, que se han dividido en cuatro subgrupos según su área de afección. Estos son: hiper-

sexualización de mujeres, "adultificación" de menores, estereotipación racial y distorsión étnica, y alteración de la identidad de género. De su observación y análisis, este trabajo pretende explicar a qué nos enfrentamos con el advenimiento de esta tecnología, qué debemos tener presente cuando la utilizamos, y de qué forma podemos mejorarla.

### 1.1 Hipersexualización de mujeres

La hipersexualización de las mujeres ha sido uno de los impactos más claros y con mayores efectos observados durante la investigación en el festival. Esta hipersexualización, observada únicamente en el colectivo femenino y en las imágenes generadas por el prototipo del CVC, provocaba tanto el aumento de determinadas partes del cuerpo como la eliminación de parte de la ropa, factor que provocaba aún mayor efecto. Coen Antens, representante del equipo técnico del CVC en el Cruïlla, expresaba que habían detectado el problema ético al "notar que la IA superdimensionaba partes del cuerpo, sobre todo en casos de ropa más ligera" [1]. Pese a la evidencia de cualquier espectador frente a dichas imágenes, gran parte de los propios participantes no se dio cuenta del cambio físico que experimentaron sus cuerpos. Es curioso analizar cómo la edad ha influido en esta identificación de la hipersexualización, siendo las participantes más mayores aquellas que han identificado el impacto de manera más rápida y dañina y, en cambio, aquellas más jóvenes en la gran mayoría de casos, no han expresado ninguna disconformidad con la imagen generada (Figura 1).

Los resultados analizados expresan en consecuencia un riesgo altísimo en la evolución y democratización de la inteligencia artificial, al no ser capaces sus usuarios de detectar falsedades en su propia imagen, algo que, trasladado a los cuerpos humanos, puede derivar en discriminación, autorrechazo o invisibilización de cualquier forma que difiera del canon estético reproducido por la IA.

### 1.2 "Adultificación" de menores

Si nos fijamos en el colectivo infantil -otro de los grupos con mayor impacto de los prototipos expuestos en el festival- encontramos también uno de los daños provocados, esta vez, por ambos prototipos (aunque el del CVC vuelve a ser el más evidente). En este caso, se



Figura 1: Percepción de la fidelidad del resultado de los prototipos, en el caso de las mujeres, en relación con la presencia de sesgos visuales, desagregada por edad  
Fuente: elaboración propia a partir de la encuesta a los usuarios.

pudo observar una "adultificación" de todos los participantes infantiles, a los que la IA generativa mostraba de la misma manera que a los adultos. Esto implica, no solamente la "adultificación" que referimos, sino también una hipersexualización a las niñas participantes de la misma forma que a las mujeres adultas.

Esta "adultificación" afectaba a la totalidad de los niños y niñas por no estar el modelo preparado para perfiles más jóvenes [1], aunque de nuevo, dicho sesgo no fue percibido ni por los propios participantes menores, ni tampoco por sus acompañantes adultos, que en algunos casos, al ser advertidos previamente de este peligro, menospreciaban el impacto por ser algo "divertido y curioso". En este sentido, la mayoría de las respuestas

obtenidas de la entrevista a los participantes del proyecto, muestra cómo este grupo de edad percibe una alta fidelidad en los resultados obtenidos, lo que significa que la imagen ha sido entendida como correcta, sin detectar ningún tipo de sesgo.

De nuevo, los resultados analizados en el festival Cruïlla sobre esta falsa reproducción de los participantes en edades más tempranas expresan un gran riesgo para esta franja de infancia tardía o preadolescencia. A lo largo de la vida, la imagen del cuerpo está en permanente (de)construcción [11], pero es durante la infancia cuando preocupaciones por el peso, las creencias relacionadas con el cuerpo y las conductas dirigidas a mejorar la apariencia física del cuerpo pueden empezar a aparecer

[24, 9]. Representaciones como las que puede reproducir la IA generativa, y en este caso reproducen los prototipos de la cátedra, pueden afectar de manera negativa a la percepción de uno mismo, puesto que no solamente "adultifican" sino que también enmarcan en un canon de belleza a todos los tipos de cuerpo, manipulando la realidad heterogénea que recibe, para acabar generando un producto peligrosamente homogéneo.

### 1.3 Estereotipación racial y distorsión étnica

Cuando hablamos de sesgos raciales producidos por la IA generativa, normalmente lo hacemos para referir aquellos casos en los que la inteligencia artificial antepone ciertos grupos étnicos por encima de otros, priorizando la representación del hombre blanco occidental [10] o reforzando estereotipos raciales o de género al representar profesiones [7, 26, 19] por ejemplo.

En nuestro caso, esta estereotipación racial se ha experimentado en el Cruïlla a través de la exageración de rasgos tanto faciales como de vestimenta o estilo, que estereotipaban la etnia atribuida al participante. Esta vez, el impacto vino dado por el prototipo de los estudiantes de la UAB, que al detectar ciertas facciones físicas o ciertos gustos calificados en la encuesta previa, atribuía una serie de características "típicas" de una etnia concreta. Esta estereotipación racial, aunque presente, no ha sido uno de los mayores impactos presentados por los prototipos, ni en frecuencia ni en intensidad, como se extrae de las respuestas de los asistentes sobre la percepción de la fidelidad de la imagen generada, donde en este caso tampoco identifican ningún sesgo (Figura 2).




Figura 2: Percepción de la fidelidad del resultado de los prototipos en relación con la presencia de sesgos visuales.

Fuente: elaboración propia a partir de la encuesta a los participantes.

Sumado a este impacto de estereotipación racial,

el prototipo también presentó cierta distorsión étnica especialmente en sus inicios. En este caso, el impacto consistía sobre todo en el cambio del color de piel o de los rasgos faciales, generando una representación étnica totalmente errónea. Aún así, durante el primer día de festival, el equipo técnico del prototipo supo detectar que el error podía ser humano, al no haber calculado correctamente la iluminación durante la realización de la fotografía, factor que provocaba una identificación demasiado oscura del color de la piel, transformando a los participantes a la etnia afroamericana. Otro elemento detectado durante el festival, que motivaba la misma distorsión étnica, fue el pelo oscuro y rizado, también asociado por la IA al colectivo. El pequeño cambio en la iluminación de la fotografía ayudó a mejorar considerablemente los resultados presentados aunque, sin embargo, no cambió la distorsión étnica hacia otro tipo de grupos, como el asiático, algo que llegó a molestar a algunos participantes.

### 1.4 Alteración de la identidad de género

El último de los impactos detectados en el festival ha sido la alteración de la identidad de género, producida de nuevo por el prototipo de la UAB. Este daño de representación, pese a ser el de menor frecuencia, ha sido quizás el que mayor impacto ha producido en los afectados. En este caso, de igual manera que pasaba con la hipersexualización, el cambio de género solo ha afectado al colectivo femenino. La alteración más clara percibida ha sido la presentación de vello facial (bigote o barba), acompañada en la mayoría de casos por una masculinización de las facciones faciales.

## 2 Conclusiones

Durante los tres días del Festival Cruïlla, en los que ambos prototipos tuvieron una afluencia de participantes considerable, no solamente se realizó la encuesta que se ha ido citando, sino que también se realizaron varias conversaciones con algunos participantes como parte de la metodología investigación-acción en la que se enmarca este trabajo. De ello, se han extraído las valoraciones y el análisis previos de los que se han podido obtener ciertas conclusiones.

En primer lugar, queda claro que la inteligencia artificial generativa es un perfecto reflejo de los valores

fomentados por la sociedad actual. Como hemos mencionado al inicio de la sección anterior, la IA se fundamenta en datos de situaciones pasadas, algo que la hace reproducir tanto discriminaciones de género como de etnia en sus representaciones. En el caso de nuestros prototipos, encontramos un claro impacto sobre el colectivo femenino, en el que la hipersexualización de todos los casos observados e incluso la alteración de la identidad de género en algunos, han sido daños de representación que solo han afectado a las mujeres (como se observa si desagregamos la percepción de la fidelidad por géneros Figura 3).




Figura 3: Percepción de la fidelidad del resultado de los prototipos en relación con la presencia de sesgos visuales, desagregada por género.

*Fuente: elaboración propia a partir de la encuesta a los participantes.*

Este impacto, en algunos casos ha afectado gravemente la sensibilidad de las participantes, como en el caso de la única encuestada mayor de 55 años, que quedaba sorprendida por el "botox y los pechos" que detectaba, y que expresó su rechazo y preocupación por los "crios" [2]. Otra participante de la franja de edad anterior (45-54 años) comentó que no se reconocía en la imagen generada, añadiendo en una conversación mantenida *in situ*: "Este cuerpo no ha sido el mío, no me siento representada en la imagen. Parece mentira que una tecnología tan moderna sexualice de esta manera el cuerpo de las

mujeres. Mi marido se enamoró de mí con el cuerpo que tengo, y no nos gusta quien sale en esa imagen. Tenemos que luchar por valorar todos los cuerpos, y luchar contra estas tendencias" [2].

Pese al enfado inicial, es fundamental comunicar los conocimientos actuales sobre las capacidades, limitaciones y daños de la IA Generativa de formas que sean comprensibles para el público en general [13]. De esa manera, se puede -y se pudo- reconducir una situación emocionalmente desagradable para enriquecer el aprendizaje colectivo que persigue como objetivo justamente esta cátedra. Como explica Coen Antes durante la entrevista realizada en el festival, "participar en la cátedra nos ha hecho más rigurosos: explicamos a la gente que la IA tiene sesgos, y es responsabilidad nuestra hacerlo evidente" [1]. Carlota Criado, miembro del equipo de estudiantes de la UAB en el festival, también describía la dualidad en la reacción presentada por los participantes: "o te lo tomas como una cosa graciosa, o no lo encajas bien, diciendo, yo no soy este, y si lo soy, no me gusto" [1].




Figura 4: Distribución del nivel de satisfacción de los encuestados (escala 1-5).

*Fuente: elaboración propia a partir de la encuesta a los participantes.*

Esta dualidad en el impacto de los daños de representación también ha presentado un elemento de análisis interesante. El segundo punto observado durante este trabajo ha sido que la gran mayoría de participantes, detectando o no los sesgos presentados, han valorado muy positivamente los prototipos, expresando un nivel de satisfacción media de los encuestados de 4,39 sobre 5 (Figura 4), que aumentaría hasta el 4,5/5 en el caso de los participantes que realizaron ambos prototipos (Figura 5).




Figura 5: Distribución del nivel de satisfacción de los participantes (escala 1-5) por prototipo.

Fuente: elaboración propia a partir de la encuesta a los participantes.

Esta amplia satisfacción también indica la baja importancia atribuida a los impactos presentes en el producto final, algo que podríamos calificar como altamente peligroso por su gran impacto potencial. Debemos ser muy conscientes de los riesgos que presenta actualmente la IA para ser capaces no solamente de identificarlos, sino también de combatirlos y mitigarlos, sobre todo por el gran impacto que pueden tener en las próximas generaciones, que no conocerán un mundo sin inteligencia artificial.

Por último, cabe destacar también la importancia de espacios como el Festival Cruïlla: ciudades efímeras que actúen como laboratorios abiertos en los que, mediante la pedagogía, se acerquen no solamente las tecnologías de vanguardia sino también los riesgos que estas entrañan. Como expresan la mayoría de encuestados, después de este *buzz* su conocimiento sobre la IA Generativa aumentó (Figura 6), algo muy positivo teniendo en cuenta el poco tiempo que demandaban los prototipos.




Figura 6: Conocimiento sobre IA generativa después de participar en el *buzz* de la UAB.

Fuente: elaboración propia a partir de la encuesta a los participantes.

## Referencias

- [1] APARICIO CRESPO, C. Entrevistes als actors implicats a la càtedra uab-cruïlla durant el festival cruïlla, 2025.
- [2] APARICIO CRESPO, C. Explotació de l'entrevista als participants dels prototips durant el festival cruïlla, 2025.
- [3] BARNETT, J. The ethical implications of generative audio models: A systematic literature review. In *Proceedings of the 2023 AAAI/ACM Conference on AI, Ethics, and Society* (Aug. 2023), pp. 146–161.
- [4] BIRD, C., UNGLESS, E., AND KASIRZADEH, A. Typology of risks of generative text-to-image models. In *Proceedings of the 2023 AAAI/ACM Conference on AI, Ethics, and Society* (2023), pp. 396–410.
- [5] BOMMASANI, R., HUDSON, D. A., ADELI, E., ALTMAN, R., ARORA, S., VON ARX, S., BERNSTEIN, M. S., BOHG, J., BOSSELUT, A., BRUNSKILL, E., ET AL. On the opportunities and risks of foundation models. *arXiv preprint arXiv:2108.07258* (2021).
- [6] CARLSON, C. *Effective FMEAs: Achieving Safe, Reliable, and Economical Products and Processes Using Failure Mode and Effects Analysis*. John Wiley & Sons, Apr. 2012.
- [7] CHEONG, M., ABEDIN, E., FERREIRA, M., REIMANN, R., CHALSON, S., ROBINSON, P., BYRNE, J., RUPPANNER, L., ALFANO, M., AND KLEIN, C. Investigating gender and racial biases in dall-e mini images. *ACM Journal on Responsible Computing* 1, 2 (2023), 1–20.
- [8] DINAN, E., ABERCROMBIE, G., BERGMAN, A. S., SPRUIT, S., HOVY, D., BOUREAU, Y.-L., AND RIESER, V. Anticipating safety issues in e2e conversational ai: Framework and tooling. *arXiv preprint arXiv:2107.03451* (2021).
- [9] FERREIRA, M. E. C., DE CASTRO, M. R., DA ROCHA MORGADO, F. F., FORTES, L. S., KAKESHITA, I. S., FILGUEIRAS, J. F., PASIAN, S. R., AND ALMEIDA, S. S. Imagem corporal e infância. In *Imagem corporal: reflexões, diretrizes e práticas de pesquisa*, M. E. C. Ferreira, M. R. de Castro, and F. F. da Rocha Morgado, Eds. Editora UFJF, Juiz de Fora, 2014, pp. 49–66.

- [10] GHOSH, S., AND CALISKAN, A. ‘person’== light-skinned, western man, and sexualization of women of color: Stereotypes in stable diffusion. In *Findings of the Association for Computational Linguistics: EMNLP 2023* (2023), pp. 6971–6985.
- [11] GLEESON, K., AND FRITH, H. (de)constructing body image. *Journal of Health Psychology* 11, 1 (2006), 79–90.
- [12] LEVESON, N. *Engineering a Safer World: Systems Thinking Applied to Safety*. The MIT Press, 2012.
- [13] LI, M., BICKERSTETH, W., TANG, N., CRANOR, L., HONG, J., SHEN, H., AND HEIDARI, H. A closer look at the existing risks of generative ai: Mapping the who, what, and how of real-world incidents. In *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society* (2025), vol. 8, pp. 1561–1573.
- [14] LIU, Y., YAO, Y., TON, J.-F., ZHANG, X., GUO, R., CHENG, H., KLOCHKOV, Y., TAUFIQ, M. F., AND LI, H. Trustworthy llms: a survey and guideline for evaluating large language models’ alignment. *arXiv preprint arXiv:2308.05374* (2023).
- [15] MACRAE, C. Learning from the failure of autonomous and intelligent systems: Accidents, safety, and sociotechnical sources of risk. *Risk Analysis* 42, 9 (2022), 1999–2025.
- [16] MUHLENBACH, F. A methodology for ethics-by-design ai systems: dealing with human value conflicts. In *2020 IEEE International Conference on Systems, Man, and Cybernetics (SMC)* (2020), IEEE, pp. 1310–1315.
- [17] NATIONAL INSTITUTE OF STANDARDS AND TECHNOLOGY. Artificial intelligence risk management framework (ai rmf 1.0). Tech. Rep. AI 100-1, National Institute of Standards and Technology, Gaithersburg, MD, 2023.
- [18] RAJI, I. D., KUMAR, I. E., HOROWITZ, A., AND SELBST, A. The fallacy of ai functionality. In *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency* (2022), pp. 959–972.
- [19] SANDOVAL-MARTÍN, T., AND MARTÍNEZ-SANZO, E. Perpetuation of gender bias in visual representation of professions in the generative ai tools dall-e and bing image creator. *Social Sciences* 13, 5 (2024), 250.
- [20] SHELBY, R., RISMANI, S., HENNE, K., MOON, A., ROSTAMZADEH, N., NICHOLAS, P., YILLA-AKBARI, N., GALLEGOS, J., SMART, A., GARCIA, E., ET AL. Sociotechnical harms of algorithmic systems: Scoping a taxonomy for harm reduction. In *Proceedings of the 2023 AAAI/ACM Conference on AI, Ethics, and Society* (2023), pp. 723–741.
- [21] SHEVLANE, T., FARQUHAR, S., GARFINKEL, B., PHUONG, M., WHITTLESTONE, J., LEUNG, J., KOKOTAJLO, D., MARCHAL, N., ANDERLJUNG, M., KOLT, N., HO, L., SIDDARTH, D., AVIN, S., HAWKINS, W., KIM, B., GABRIEL, I., BOLINA, V., CLARK, J., BENGIO, Y., CHRISTIANO, P., AND DAFOE, A. Model evaluation for extreme risks. *arXiv preprint arXiv:2305.15324* (Sept. 2023).
- [22] SLATTERY, P., SAERI, A. K., GRUNDY, E. A., GRAHAM, J., NOETEL, M., UUK, R., DAO, J., POUR, S., CASPER, S., AND THOMPSON, N. The ai risk repository: A comprehensive meta-review, database, and taxonomy of risks from artificial intelligence. *arXiv preprint arXiv:2408.12622* (2024).
- [23] SMITH, J. J., DENG, W. H., SMITH, W. H., SAP, M., DECARIO, N., AND DODGE, J. The generative ai ethics playbook. *arXiv preprint arXiv:2501.10383* (2024). CC BY 4.0.
- [24] SMOLAK, L. Body image development in childhood. In *Body Image: A Handbook of Science, Practice, and Prevention*, T. F. Cash and L. Smolak, Eds., 2 ed. The Guilford Press, New York, 2011, pp. 67–75.
- [25] SOLAIMAN, I., TALAT, Z., AGNEW, W., AHMAD, L., BAKER, D., BLODGETT, S. L., CHEN, C., DAUMÉ III, H., DODGE, J., DUAN, I., ET AL. Evaluating the social impact of generative ai systems in systems and society. *arXiv preprint arXiv:2306.05949* (2023).
- [26] SUN, L., WEI, M., SUN, Y., SUH, Y. J., SHEN, L., AND YANG, S. Smiling women pitching down: Auditing representational and presentational gender biases in image-generative ai. *Journal of Computer-Mediated Communication* 29, 1 (2024), zmad045.
- [27] WEIDINGER, L., MELLOR, J., RAUH, M., GRIFFIN, C., UESATO, J., HUANG, P.-S., CHENG, M., GLAESE, M.,

BALLE, B., KASIRZADEH, A., ET AL. Ethical and social risks of harm from language models. *arXiv preprint arXiv:2112.04359* (2021).